

研究論文

二部グラフ検索を活用した RAG に基づく推薦理由の説得力の向上 ～対話型コスメ推薦システム～

Improving the Persuasiveness of RAG-based Recommendation Reasons using Bipartite Graph Exploration –Interactive cosmetics Recommendation System–

新垣 遼馬¹, 伏見 卓恭^{1*}

Ryoma ARAKAKI¹, Takayasu FUSHIMI^{1*}

¹ 東京工科大学 コンピュータサイエンス学部

School of Computer Science, Tokyo University of Technology

〒 192-0982 東京都八王子市片倉町 1 4 0 4 - 1

E-mail: c0b21191a5,fushimity@edu.teu.ac.jp

* 連絡先著者 Corresponding Author

本研究では、レビュー文を外部データとして活用し、Retrieval-Augmented Generation (RAG) 技術を実装した大規模言語モデルを用いたコスメ推薦システムを構築する。RAG では、まずベクトル検索によりユーザーの問い合わせに関連するレビュー文を検索し、それを基に LLM が推薦理由や商品説明を生成する。しかし、一般的なベクトル検索のみでは、検索されたレビュー文が特定のアイテムの人気度やおすすめ度を十分に反映していない場合があり、推薦理由として説得力に欠ける可能性がある。そこで、本研究ではベクトル検索に加えて、「二部グラフ検索」という新たな仕組みを導入する。この手法では、検索されたレビュー文に加えて、当該アイテムに対する他の関連レビュー文や、検索されたレビュー文を投稿したレビュアーが他の商品について投稿したレビュー文も考慮する。これにより、アイテムに対する多面的な評価をより深く考慮できるようになり、ユーザー満足度の向上が期待される。実データを用いた評価実験では、ベクトル検索のみを用いた推薦システムと比較して、検索結果に基づく推薦理由の説得力が向上し、ユーザー満足度を高める可能性が示された。

In this study, we construct a cosmetic recommendation system utilizing a Large Language Model (LLM) equipped with Retrieval-Augmented Generation (RAG) technology, incorporating review texts as external data. RAG first retrieves relevant review texts based on the user's query through vector search and then generates recommendation explanations and product descriptions using the LLM. However, standard vector search alone may not sufficiently reflect an item's popularity or recommendation relevance in the retrieved reviews, potentially leading to less convincing recommendation rationales. To address this, we introduce a mechanism called "bipartite graph retrieval" in addition to vector search. This approach considers not only the retrieved review texts but also other related reviews about the target item, as well as reviews written by the reviewers who posted the retrieved reviews about other products. By incorporating these additional perspectives, the system can better capture multifaceted evaluations of items and users' preferences, ultimately enhancing user satisfaction. Evaluation experiments using real-world data demonstrated that, compared to a recommendation system relying solely on vector search, our approach improved the persuasiveness of recommendation rationales based on retrieved results and has the potential to enhance user satisfaction.

キーワード: 大規模言語モデル, 検索拡張生成, 情報推薦, 二部グラフ, 説得力のある推薦理由

Keywords: Large Language Model, Retrieval-Augmented Generation, Information Recommendation, Bipartite Graph, Persuasiveness of Recommendation Reasons

1 はじめに

近年、大規模言語モデル (Large Language Model; LLM) の性能が向上し、社会の中の多様なサービスに LLM が使用されるようになってきた。応用例として、カスタマーサポートにおける自動応答システムやチャットボットとして使用され、顧客からの質問に即座に回答したり、サポートリクエスト処理をしたりする。また、医療やヘルスケア分野においては、患者の診断や治療法に関する情報を提供したり、医療文献の解析を行ったりすることで、医療従事者の質問に対して情報提供を行うツールとして利用されている。これらの応用は、LLM の能力が進歩するにつれ、さらに広がると考えられている。

一方、既存の推薦システムはユーザーの明確な選択肢を前提とすることが多く、柔軟な自然言語によるインタラクションを実現することは難しい。これに対して、LLM はユーザーの自由形式のクエリをインターフェースとして直接解釈し、個別のニーズに応じた応答を生成することが可能である。しかし、LLM 単体では専門的または特化した知識に限界があり、ハルシネーションなどの問題は往々にして起こり得る。この課題に対処するために注目されているのが、RAG (Retrieval-Augmented Generation) である^[1]。RAG は、LLM と情報検索技術を組み合わせ、外部データを参照することで、LLM の不足する知識を補うアプローチである。特に、レビューのようなテキストデータを外部データとして活用できる柔軟性を持ち、商品推薦システムにおいてもその有効性が期待される。レビューは、レビューアの評価や意見が豊富に含まれるため、個々のニーズに応じた商品推薦の基盤となりうる。また、LLM を用いない従来の商品推薦では、レビューアとアイテムの二部グラフを考慮した推薦が行われる。本研究では、レビュー文を介してつながるレビューアとアイテムの二部グラフ的な関係から、二部グラフ検索 (Bipartite-Graph Retrieval; BGR) と呼ぶ。

本研究では、「説得力」を関連度、信頼度、わかりやすさの3要素から構成される概念と定義し、説得力のある理由を添えた推薦を実現することを目的とする。この目的のために、レビュー履歴に対する標準的なベクトル検索 (Vector Retrieval; VR) により関連性の高いレビューを参照し、さらに BGR により周辺レビューも考慮することで**信頼度**を補強する。また、既存のチャットボットなどが備える「ユー

ザーの自然言語クエリへの柔軟性」と「自然言語による応答の**わかりやすさ**」を担保するため、LLM をインターフェースとして用いる。

以上を踏まえて、本研究で構築するシステムは、ユーザーからの多様な表現のクエリを LLM が対話を通じて理解し、ユーザーのニーズを抽出して、レビュー文が登録されたデータベースから類似するレビュー文を VR により検索する。その後、そのレビュー文の対象となるアイテムに対する他のレビュー、そのレビュー文を投稿したレビューアの他のレビューを BGR で取得し、LLM に渡す。このような多面的な情報を統合して推薦理由を構築することで、納得感のある推薦を可能にする。提案する推薦システムのイメージ図 1 に示す。




図 1: 提案する推薦システムのイメージ図

本稿の構成は以下の通りである。最初に2節で関連研究を俯瞰して本研究の立ち位置を明らかにし、3節で提案システムの詳細について述べる。つづいて4で述べる実データを用いて提案システムの出力結果の比較を5節、アンケート結果を6節で言及する。さいごに7節で本稿のまとめを述べる。

2 関連研究

本節では、本研究と関連する先行研究を、LLM と RAG を基盤とする推薦手法の観点から整理する。特に、RAG の検索段階や生成段階を強化して推薦性能を向上させる研究、検索と生成のモジュール間の情報整合性を重視する研究、およびマルチモーダル情報を統合する研究を概観し、本研究との共通点と相違点を明らかにする。

2.1 RAG の検索段階を強化した推薦手法

RALLRec^[2] は、従来の RAG がテキストセマンティクスに依存し過ぎることによる関連アイテム取得精度の限界を克服するため、アイテムの詳細説明を LLM で生成し、テキストと協調セマンティクスを統合した共同表現学習を行う。さらに、ユーザ嗜好の時間的变化を考慮した再ランキングにより、より関連性の高いアイテムを優先的に取得する。このアプローチは、検索段階での表現強化と再ランキングにより精度を高める点で、本研究と同様に検索段階の高度化を志向しているが、協調フィルタリング由来の情報や時間的要素を利用している点で異なる。

RALLREC+^[3] は、RALLRec を拡張し、検索段階における詳細アイテム記述生成と協調的意味表現の統合に加えて、推論型 LLM を活用した生成段階の強化を行う。これにより、推薦結果の説明性や一貫性を高めている。本研究は推論型 LLM の特殊な導入は行わず、レビュー文と二部グラフ検索に基づく多面的情報取得によって説得力を確保している。

RAGX11Rec^[4] は、RankRAG による外部コンテキストの再ランキングと軽量トランスフォーマーモデルを組み合わせ、コールドスタート環境でも高速かつ高精度な推薦を可能にした。このような再ランキングを組み込むアプローチは、本研究の二部グラフ検索による情報補完と同様に、単純なベクトル検索の限界を補う発想に位置づけられる。

2.2 検索-生成モジュール間の整合性を重視した RAG

DPA-RAG^[5] は、リトリバーと LLM の間の嗜好不一致を解消するため、外部嗜好整合と内部嗜好整合を同時に実現するフレームワークを提案している。具体的には、LLM が生成時に好む知識を抽出・合成する 5 種類のクエリ拡張戦略を導入し、マルチグレインの嗜好整合タスクを通じて関連知識を選択的にフィルタリングする。このアプローチは、取得知識の適合性を重視する点で本研究と共通するが、本研究は嗜好整合という明示のプロセスではなく、二部グラフ検索によりレビュー間の関係性を拡張し、多面的な関連レビューを取得することで実質的な適合性向上を図っている。

2.3 知識グラフを活用した RAG 推薦

一方、知識グラフ (KG) を活用する RAG 推薦も多数提案されている。K-RagRec^[6] は、GNN を用いて KG の多層表現を活用し、詳細な知識サブグラフを効率的に検索して推薦に利用する。KERAG_R^[7] は、GraphRAG と GAT により関連性の高いトリプルを選択し、知識強化型の指示微調整を行う。LlamaRec-LKG-RAG^[8] は、異種 KG から関連性の高い部分グラフを抽出してプロンプトに組み込み、効率的で説明可能なランキングを行う。また、G-CRS^[9] は、会話履歴から構築したグラフを用いて関連アイテムや過去会話を検索し、LLM のインコンテキスト学習により会話型推薦を実現している。これらの手法は構造化知識を活用して推論精度を高めるが、本研究は KG を使用せず、レビュー文と二部グラフ構造に基づく情報補完に特化している点で異なる。

2.4 マルチモーダル情報を活用した RAG 推薦

RAG-VISUALREC^[10] は、映画推薦において映像のビジュアル特徴と LLM 生成のテキスト説明を CCA で融合し、多モーダル統合により精度と多様性を向上させた。本研究はテキスト情報のみを対象とするが、推薦理由の説得力を高めるという点で方向性を共有する。

2.5 本研究の位置づけ

以上を踏まえて、本研究は RAG を基盤とし、検索段階において二部グラフ検索を組み合わせることで、多面的に関連性の高いレビュー情報を取得する点、レビュー文を対象とし、ユーザ嗜好に近い他者レビューや同一商品の別レビューを補完することで推薦理由の納得感を高める点、知識グラフや画像・映像などのマルチモーダル情報を用いず、テキストレビューと二部グラフ構造に特化する点に特徴を有する。既存の RAG 推薦研究と比べ、検索段階の拡張と推薦理由の納得感向上に主眼を置く点で新規性を持つ。

3 提案システム

提案手法は、「gemma-2-27b-it.f16.Q8_0.gguf」(<https://huggingface.co/dahara1/gemma-2-27b-it-gguf-japanese-imatrix>) という LLM をインタフェースとして、対話的にユーザーのニーズを抽出し、ベクトル検索により関連レビューを検索する。gemma-2 は、Web 上のデータをクロールし訓練されているため、化粧品に関する知識をある程度持っている。

本研究では、以下の要件を満たすレビューとその対象アイテムの情報を LLM に渡すことにより、関連性だけでなく多面的な情報を加味した説得力のある理由を添えてアイテムを推薦する：

- 関連度：クエリに類似するレビューの対象アイテム
- 推奨度・非推奨度：スコアが {高い | 低い} レビューの対象アイテム
- 信頼度：{レビュー数が多い | 属性が似ている} レビューによりレビューされたアイテム
- 人気度：被レビュー数の多いアイテム
- 網羅性：クエリに含まれない関連する概念を含むレビューの対象アイテム

関連度は、ベクトル検索において、類似レビューに絞り込むことで満たすことができる。推奨、非推奨度は、レビューの感情分析により判別できるが、システムへの導入は今後の課題とする。信頼度は、二部グラフ検索において、レビュー数が多いレビュアーや年齢、肌質が似ている他のレビュアーのレビューも考慮し、多面的な情報を取り込むことで満たすことができる。人気度は、二部グラフ検索において、アイテムの被レビュー数や平均スコアなどにより絞り込むことで満たすことができる。網羅性については、一般的にはナレッジグラフ検索 (Knowledge-Graph Retrieval) で補うことができるが、本研究では扱わず今後の課題とする。以上のように、LLM をインタフェースにすることで推薦理由のわかりやすさを担保し、関連度と信頼度を満たす多面的なレビュー群を用いて推薦理由を構築することで、ユーザーに取って納得感のある、すなわち、説得力のある推薦理由を提示することを目指す。また、関連度、信頼度、人気度は、絞り込む条件により結果が変化するためユーザーに指定してもらうのが良いが、実験では固定した値に設定する。

推薦システムの概要を以下に示す：

1. ユーザー：チャットを介して問い合わせる（クエリ）；
2. システム：対話的にユーザーのニーズや特性（肌質、年齢など）を抽出する；
3. システム：レビューデータベースに対してベクトル検索 (VR) し、類似レビュー群（レビュー文、アイテム情報、レビュアー情報）を得る；
4. システム：類似レビュー 1 件ごとをクエリとして二部グラフ検索 (BGR) し、関連レビューを得る；
5. システム：得られた関連レビューを LLM に渡し、 g 件のレビューと対象アイテムを選ぶ；
6. システム：おすすめアイテムと自然言語による理由をユーザーに返す；




図 2: 二部グラフ検索による関連レビュー (Top-1 検索の場合の例)

まず、あらかじめレビュー文と付属するメタ情報を Embedding し、ベクトルデータベースに格納しておく。Embedding には「intfloat/multilingual-e5-large」(<https://huggingface.co/intfloat/multilingual-e5-large>) を使用する。ここで、メタ情報として、アイテム名、ブランド、レビュアーの性別、年齢、肌質を指定した。

手順1のチャットを介した問い合わせでは、たとえば、「レチノールを含むおすすめ商品を教えて」や「乾燥肌に合う化粧水はどんなもの？」などアイテム名、カテゴリ名、成分名、症状、テクスチャ、価格帯、肌質などのキーワードを含む多様なクエリが入力される。

手順2のニーズと特性抽出では、ベクトル検索時に必要な情報のうちユーザーからの問い合わせ（手順1）に含まれていない情報を対話を通じて引き出す。具体的には、事前に抽出対象とする属性項目（性別、年齢、肌質、肌トラブル、商品カテゴリ）を定義する。そして、ユーザーが手順1で入力した内容をLLMが解析し、各属性の値を推定し、不明な項目に関しては「不明」とした構造化データ（JSON）を出力する。JSON作成時に用いるプロンプトを図3に示す。

```
def extract_info_with_gemini(user_input):
    prompt = f"""
    以下のユーザー入力文から、次の5つの属性を抽出してください。
    - 性別
    - 年齢
    - 肌質
    - 肌トラブル
    - 商品カテゴリ

    出力は必ず以下のjson形式で返してください。未知の場合は "不明" としてください。

    {{
      "性別": "...",
      "年齢": "...",
      "肌質": "...",
      "肌トラブル": "...",
      "商品カテゴリ": "..."
    }}

    ユーザー入力: {user_input}
    """
```

図 3: ユーザー属性抽出のためのプロンプト

LLM を用いることにより、性別や年齢といった明示的に含まれる情報だけでなく、文脈から推定可能な属性も抽出可能となる。さらに、抽出結果に基づき、不足している属性情報を特定し、その情報をユーザーに自然言語で追加質問する。追加質問に対してユーザーが入力しなかった場合は、強要せず得られた情報のみを用いる。

たとえば、手順1の問い合わせの中に性別、肌質、肌トラブルに関する情報が含まれていなかった場合、システム側から「あなたは20歳で、化粧水カテゴリのアイテムについて気になっていますね。よろしければ性別、肌質、肌トラブルも教えて下さい。」という応答を返し、ユーザーにこれらの情報の入力を促す。

手順3のベクトル検索では、クエリベクトルと、データベースに登録されたレビュー文とメタ情報

（アイテム名など）をベクトル化したものを比較し、最も類似度の高いレビューを検索する。商品説明文ではなく、ニーズに則したレビュー文からアイテムを検索する点に特徴がある。具体的には、プロンプト「以下のユーザー入力と属性情報をもとに、自然な1文の検索用クエリを生成してください。」により手順1と2で得られた情報を統合し、エンコーダによりクエリベクトル $\mathbf{q}$ を作成する。参照するデータベース内のベクトルは、レビュー文の後ろに「このレビューを投稿したユーザーの年齢は {age}, 性別は {gender}, ...」のようにレビュー文とレビューアの属性情報を統合し、エンコーダにより1つのベクトル $\mathbf{r}$ として作成される。データベースには、1つのレビューが1つのベクトルとして格納されている。関連度（類似度）は、クエリベクトル $\mathbf{q}$ とレビューベクトル $\mathbf{r}$ とのコサイン類似度により算出し、類似度上位 k 件のレビュー集合を $\mathcal{R}_k(\mathbf{q}) = \{r_1, r_2, \dots, r_k\}$ とし、次のステップに出力する。ベクトル検索により、関連度要件を満たす。

手順4の二部グラフ検索では、図2に示すように、ベクトル検索で得られた類似レビュー（図中の赤色矢印）について、レビュー対象のアイテムに対する他のレビューアからのレビュー（図中の緑色矢印）を検索する。これらの中には、当該アイテムに対するポジティブなレビューやネガティブなレビューが含まれるため、LLMがおすすめするか否かの判断材料となる。また、類似レビューを投稿したレビューアの他のレビュー（図中の青色矢印）も検索する。形式的には、レビューア集合を $\mathcal{U}$ 、アイテム集合を $\mathcal{I}$ 、レビュー集合を $\mathcal{R} = \{(u, i) \mid u \in \mathcal{U}, i \in \mathcal{I}\}$ とし、これらから構成される二部グラフを $B = (\mathcal{U}, \mathcal{I}, \mathcal{R})$ と定義する。ここで、 $(u, i) \in \mathcal{R}$ はレビューア $u \in \mathcal{U}$ がアイテム $i \in \mathcal{I}$ に対するレビューを投稿したことを表す。ベクトル検索により得られた各レビュー（図中の赤色矢印） $r \in \mathcal{R}_k(\mathbf{q})$ が対象とするアイテムの集合を以下のように定義する：

$$\mathcal{I}(\mathbf{q}) = \{r.item \in \mathcal{I} \mid r \in \mathcal{R}_k(\mathbf{q})\}.$$

アイテム集合 $\mathcal{I}(\mathbf{q})$ の各アイテムに対する他のレビューアからのレビュー（図中の緑色矢印）の集合を定義する：

$$\mathcal{R}^{(U)} = \{r \in \mathcal{R}_i \mid i \in \mathcal{I}(\mathbf{q})\}.$$

ここで、 $\mathcal{R}_i$ はアイテム i に対するレビューの集合を表す。さらに、レビュー $r \in \mathcal{R}^{(U)}$ をレビューし

たレビュアーの集合を定義する：

$$\mathcal{U}^{(U)} = \{r.user \mid r \in \mathcal{R}^{(U)}\}.$$

同様に、ベクトル検索により得られた各レビュー（図中の赤色矢印） $r \in \mathcal{R}_k(\mathbf{q})$ を投稿したレビュアーの集合を以下のように定義する：

$$\mathcal{U}(\mathbf{q}) = \{r.user \in \mathcal{U} \mid r \in \mathcal{R}_k(\mathbf{q})\}.$$

レビュアー集合 $\mathcal{U}(\mathbf{q})$ の各レビュアーが投稿した他のアイテムへのレビュー（図中の青色矢印）の集合を定義する：

$$\mathcal{R}^{(I)} = \{r \in \mathcal{R}_u, u \in \mathcal{U}(\mathbf{q})\}.$$

ここで、 $\mathcal{R}_u$ はレビュアー u が投稿したレビューの集合を表す。さらに、レビュー $r \in \mathcal{R}^{(I)}$ の対象アイテムの集合を定義する：

$$\mathcal{I}^{(I)} = \{r.item \mid r \in \mathcal{R}^{(I)}\}.$$

得られたレビュアーの集合 $\mathcal{U}^{(U)} \cup \mathcal{U}(\mathbf{q})$ に対して、ユーザーとの年齢差が ± 5 で、肌質が同じレビュアーを選定し、レビュー数が多い h 件を選ぶ： $\tilde{\mathcal{U}}_h$ 。これにより、信頼度要件を満たす。なお、手順2までで得られなかった属性情報は、絞り込みを行わない。

同様に、得られたアイテムの集合 $\mathcal{I}(\mathbf{q}) \cup \mathcal{I}^{(I)}$ に対して、被レビュー数が多い f 件のアイテムを選ぶ： $\tilde{\mathcal{I}}_f$ 。これにより、人気度要件を満たす。

フィルタリングしたレビュアー集合 $\tilde{\mathcal{U}}_h$ とアイテム集合 $\tilde{\mathcal{I}}_f$ から構築した誘導サブグラフ $\tilde{B} = (\tilde{\mathcal{U}}_h, \tilde{\mathcal{I}}_f, \tilde{\mathcal{R}})$ のレビュー集合 $\tilde{\mathcal{R}}$ を次のステップに出力する。この際、 $\tilde{\mathcal{R}}$ 内のレビューは、対象アイテムやレビュアーによって区別はしない。

手順5の**レビューとアイテムの選定**では、手順4で得られたレビュー集合を LLM に渡し、最終的に g 件のレビューとその対象アイテムを選ぶ。

手順6の**レスポンス**では、LLM が選んだアイテムとレビューから理由を添えてユーザーに返す。

4 データセット

本研究では、コスメ・化粧品に関する日本最大のレビューサイトであるアットコスメ (<https://www.cosme.net/>) から収集したレビューデータ、アイテムデータ、レビュアーデータを用いる。スキンケア・基礎化粧品、うるおい、毛穴の3カテゴリに含

まれる全 6,904 アイテムに関する全 478,064 レビューからの全 2,243,612 レビューを対象とする。レビュー数の分布を図4に、レビュアーの年齢層、肌質の分布を図5に示す。レビュー情報については、レビューID、レビュアーID、年齢、肌質、レビュー文、価格、レビュー数、スコア、リピートしたかどうかをメタデータとして含める。商品情報としては商品名、ブランド、アイテムID、カテゴリーをメタデータとして使用する。

5 出力結果の比較による定性評価

この節では、LLM による推薦 (RAG なし)、ベクトル検索を用いた推薦 (RAG (VR))、ベクトル検索と二部グラフ検索を用いた推薦 (RAG (VR+BGR)) の3つのシステムによる出力である推薦商品と推薦理由を比較し、定性的に評価する。今回の実験では、システムのハイパーパラメータは、ベクトル検索件数 $k = 1$ 、レビュアー絞り込み件数 $h = 10$ 、アイテム絞り込み件数 $f = 10$ 、LLM による選定アイテム数 $g = 1$ と設定した。

表1は、RAG なし、RAG (VR)、提案システムである RAG (VR+BGR) の出力である。対象ユーザーの設定としては21歳敏感肌とし、質問文は「ニキビに効く化粧水を教えてください」というクエリに対する出力である。

RAG なしシステムによる推薦結果では、ベクトル検索は行わず、単に質問文とユーザーの情報から LLM が回答を生成している。推薦結果は一見すると参考になる情報のように見える。推薦結果の中に「賦活化粧水」という具体的な商品名を上げて推薦しており、「敏感肌の21歳の方には、エンビロンの賦活化粧水を薦めます。」「エンビロンの化粧品は、敏感肌やニキビに悩む人のために作られたブランドです。」などより具体的に商品を推薦している。「エンビロン」については実在するブランドであり、ブランドの口コミからも刺激が少ないスキンケア用品と書き込まれていることが多い印象を受けた。しかし、「賦活化粧水」についてはエンビロン公式サイトで検索しても見つからず、実在しない商品名であることが分かった。「賦活化粧水は、肌を健やかに保つ効果があり、ニキビの予防や改善も期待できます。」とあるように、あたかも実在する商品のよう

に推薦しており、RAG を使わない手法ではハルシネーションが起きる結果となった。

表 1: RAG 手法による商品推薦の実験結果の比較

	RAG なし	RAG (VR のみ)	RAG (VR + BGR)
ユーザーのクエリ文	ニキビに効く化粧水を教えてください		
検索の結果	無し	ニキビによく出る皮膚に一番いい化粧水と思う	VR: ニキビによく出る皮膚に一番いい化粧水と思う BGR: 信頼している, お助けコスメです! 汗疹の悪化や, 湿疹, かぶれなど, あらゆる肌荒れで, 何をつけてもだめなときは, これに限る～頼りにしてま～す
検索結果を統合したプロンプト	以下の情報をもとに質問者に商品を教えてください. 1. 商品名 2. ブランド 3. レビュー内容から商品の特徴をまとめて 質問: ニキビに効く化粧水を教えてください 以下は質問者の情報です: 年齢: 21 肌タイプ: 敏感肌	以下の情報をもとに質問者に商品を教えてください. 1. 商品名 2. ブランド 3. レビュー内容から商品の特徴をまとめて 質問: ニキビに効く化粧水を教えてください 以下は質問者の情報です: 年齢: 21 肌タイプ: 敏感肌 以下は検索したレビュー情報です: 商品名: キールズ ハーバル トナー CL アルコールフリー ブランド: KIEHL'S SINCE 1851(キールズ) 年齢: 32 歳 レビュー内容: ニキビよく出る皮膚に一番いい化粧水と思う	以下の情報をもとに質問者に商品を教えてください. 1. 商品名 2. ブランド 3. レビュー内容から商品の特徴をまとめて 質問: ニキビに効く化粧水を教えてください 以下は質問者の情報です: 年齢: 21 肌タイプ: 敏感肌 以下は検索したレビュー情報です: 商品名: キールズ ハーバル トナー CL アルコールフリー ブランド: KIEHL'S SINCE 1851(キールズ) 年齢: 21 歳 肌質: 敏感肌 レビュー内容: 信頼している, お助けコスメです! 汗疹の悪化や, 湿疹, かぶれなど, あらゆる肌荒れで, 何をつけてもだめなときは, これに限る～頼りにしてま～す
LLM の推薦結果	推薦する商品名, ブランド, 内容から推測できる推薦理由は以下の通り. 商品名: 賦活化粧水 ブランド: エンビロン 内容から推測できる推薦理由: 敏感肌に悩む 21 歳の方には, エンビロンの賦活化粧水を薦めます. エンビロンの化粧品は, 敏感肌やニキビに悩む人々のために作られたブランドです. 賦活化粧水は, 肌を健やかに保つ効果があり, ニキビの予防や改善も期待できます.	質問者が求める条件を満たす商品は, キールズ ハーバル トナー CL アルコールフリーです. 敏感肌である質問者に合うアルコールフリーの化粧水で, ニキビにも効果的と考えられます.	商品名: キールズ ハーバル トナー CL アルコールフリー ブランド: KIEHL'S SINCE 1851(キールズ) 推薦理由: * レビューで「ニキビよく出る皮膚に一番いい化粧水と思う」と記載されていることから, ニキビ肌の方にも効果が期待できます. * 21 歳敏感肌の方が「信頼している, お助けコスメです!」とレビューしており, 敏感肌の方でも使用できる可能性が高いです. * アルコールフリーなので, 敏感肌の方でも刺激が少なく安心して使えると考えられます.




図 4: レビュー数分布




図 5: レビューアの特性格分布

RAG (VR) システムでは、関連度要件を満たすことを目的としている。質問文に対して「ニキビよく出る皮膚に一番いい化粧水だと思う」というレビュー文を抜き出してきており、質問者のニーズに近いレビュー文を取得することができている。LLM の推薦結果としては「キールズ ハーバル トナー CL アルコールフリー」と VR で得られた商品名を挙げており、なおかつ「ニキビにも効果的と考えられます」という推薦文も VR で得られたレビュー内容を踏まえた回答になっている。しかし、今回のように質問文が短い場合、質問者の肌質や年齢を十分考慮できず、32 歳のレビューアのレビューが選ばれてしまっている。また、得られるレビューの文長も短くなるが多いため、質問者にとって説得力のある推薦文を出力することが困難である。結論として、実在する商品と商品に対するレビューを踏まえた回答結果となっているが、質問者の肌質や年齢が異なっており質問者にとって適切な推薦が行えているとは言えない結果となった。

RAG (VR+BGR) システムでは、関連度要件に加え、信頼度と人気度要件を満たすことを目的としている。VR により検索されたレビューを元に、BGR により年齢や肌質を満たしつつ (信頼度)、レビュー数が多いレビューを抽出できた。その結果、LLM の推薦結果として実在する商品を推薦できしており、加えて推薦文に関しては大きな違いがみられた。具体的には、「* 21 歳敏感肌の方が信頼している、お助けコスメです! とレビューしており、敏感肌の方でも使用できる可能性が高いです。*」というように、質問者と近い属性を持つレビューアのレビューを引用して推薦できている。このように、ユーザーの満足度向上が期待できる推薦理由を添えることができています。

まとめると、RAG なしの手法では、質問文とユーザー情報をもとに LLM が回答を生成するが、具体的な商品名を挙げる一方で、実在しない商品を推薦するなど、ハルシネーションが発生する可能性が高い。このため、生成された推薦結果の信頼性や正確性に

課題があることが明らかになった。一見すると説得力のある推薦理由であっても、根拠となる情報が不足している場合、ユーザーに誤解を与えるリスクがある。一方、RAG (VR) を活用した手法では、ベクトル検索によって得られた関連性の高いレビューを活用し、実在する商品を推薦する点で信頼性が向上している。しかし、レビュー取得時に質問者の肌質や年齢といった個別の特徴が十分に考慮されていなかったり、周辺レビューも考慮していないため、推薦理由が質問者にとって納得感があるかは疑問が残る。RAG (VR+BGR) では、RAG (VR) の欠点を補完するために、類似レビュアーのレビューを取り入れたアプローチを採用している。この手法により、質問者と近い属性を持つレビュアーのレビューを引用した推薦理由が生成され、納得感が高まる結果となっている。ユーザー個別の特徴を反映した推薦理由の提示が可能となり、信頼性や満足度が向上が期待できる。これらの点を客観的に評価すべく、アンケートによる調査を実施した。

6 アンケートによる定量評価

この節では、提案手法である RAG (VR + BGR) による推薦商品と推薦理由が適切であるか、RAG (VR) と比較評価するためにアンケートを行った。対象は、東京工科大学に所属する大学生、大学院生、教員である。複数の授業で被験者を募り、希望した方をフィルタリングせずに採用した。各システムの出力（推薦アイテムや推薦理由）を提示し、Google フォームにより質問に対して回答してもらった。回答者の性別、年齢は収集していないが、18 歳から 60 歳の男女 317 件の回答を得た。

6.1 アンケート内容

アンケートは、以下の内容を Google フォームにより作成した。

- セクション 1: コスメへの知識・関心についての質問
 - － 月にどのくらい化粧品を買いますか?: 10000 円以上 / 5000 円～10000 円 / 1000 円～5000 円 / 0 円～1000 円

- － コスメや美容に関する知識はどのくらいありますか?: 非常に詳しい / 基本的な知識はある / ほとんど知らない
- － コスメを買う際に商品レビューをどの程度参考にしていますか?: 非常に参考にする / まあまあ参考にする / 参考にしない
- － AI とチャット形式で話しながら、商品を推薦するシステムがあったらいいと思いますか?: ぜひあってほしい / あれば使ってみたい / 特に必要とは思わない / あまり興味がない
- セクション 2～4: 推薦例 1～3 (システムへの質問文 / システム A の推薦商品と推薦理由 / システム B の推薦商品と推薦理由)
 - － 質問に対して、推薦された商品に対する満足度を教えてください。: 非常に満足 / 満足 / 普通 / やや不満 / 非常に不満 / わからない
 - － 二つのシステムについて推薦理由が分かりやすかったと感じるのはどちらの結果ですか?: システム A / システム B / どちらも同じくらいわかりやすい / どちらもわかりにくい
 - － 二つのシステムについて推薦理由に納得感を感じたのはどちらですか?: システム A / システム B / どちらも同じくらい / どちらも納得できない
 - － 二つのシステムについて推薦理由が参考になったと思うのはどちらですか?: システム A / システム B / どちらも同じくらい参考になる / どちらも参考にならない
- セクション 5: 推薦理由についての質問
 - － 推薦理由が詳細に記載されていることについてどう感じますか?: 詳細な理由があると安心できる / ある程度の理由があれば十分 / 簡潔な情報のほうがいい / 推薦理由は特に必要ない
 - － 今回提示した推薦理由は、すべて実際の商品レビューを基に生成していますが、レビューが基になっている点について、どの程度参考になりましたか?: 非常に

表 2: 推薦理由

	システム A	システム B
アイテム 1	質問者が求める条件を満たす商品は、キールズハーバルトナー CL アルコールフリーです。敏感肌である質問者に合うアルコールフリーの化粧水で、ニキビにも効果的と考えられます。	レビューで「ニキビよく出る皮膚に一番いい化粧水と思う」と記載されていることから、ニキビ肌の方にも効果が期待できます。21 歳敏感肌の方が「信頼している、お助けコスメです!」とレビューしており、敏感肌の方でも使用できる可能性が高いです。アルコールフリーなので、敏感肌の方でも刺激が少なく安心して使えると考えられます
アイテム 2	敏感肌さんにおすすめ!化粧のノリアップにポール&ジョー ボーテのプロテクティング ファンデーション プライマー 21 歳で敏感肌とのことですね。化粧のノリを良くしたいなら、ポール&ジョー ボーテのプロテクティングファンデーションプライマーをおすすめします! レビューでも「化粧ノリが良くなる」と評判です。このプライマーは、メイク前の肌を整えてくれるだけでなく、肌への負担も少なく敏感肌の方にもおすすめです。	プロテクティング ファンデーション プライマーのおすすめポイント 21 歳敏感肌さんにもおすすめ!レビューによると、ファンデーション無しでも肌がきれいになるとのことなので、敏感肌の方でも安心して使えそうです。化粧のノリが良くなるだけでなく、肌を保護する効果も期待できるプライマーです。ポール&ジョーボーテの特徴: 可愛いパッケージで、持っているだけで気分が上がります。上質な成分を使用し、肌に優しい処方です。まとめプロテクティング ファンデーション プライマーは、敏感肌の方でも安心して使える、化粧ノリを良くしてくれるプライマーです。肌の保護効果も期待できるので、おすすめです。
アイテム 3	ルルルン プレシャス RED(モイスト) は、目の周りと鼻の下が浮きやすいという悩みをお持ちの方におすすめです。美容液たっぷり顔にぴったり密着し、使用後はお肌モチモチになります。液ダレもしないのも嬉しいポイントです。夜に使用する場合には、パックのあとにさらにクリームを塗るとより保湿されると思います。敏感肌の方にもおすすめです。	ルルルン プレシャス RED(モイスト) 推薦理由 21 歳、敏感肌の方におすすめです。レビューに基づく特徴: 密着力が高い: 目の周りや鼻の下など、顔の凹凸にもしっかりフィットし、液ダレもしない。美容液たっぷり: モチモチ肌に導く潤いを提供する。ベタつかず快適: 朝用にもおすすめの使用感。コスパが良い: 毎日使いしやすい価格設定。敏感肌の方への配慮: レビューでは刺激についての言及はありませんでした。しかし、成分表を確認し、ご自身の肌に合うか事前に確認することをお勧めします。夜のスキンケアに: レビューにもあるように、パック後クリームを重ねることでさらに保湿効果を高めることができます。総合評価: ルルルン プレシャス RED(モイスト) は、敏感肌の方でも安心して使える、高保湿でコスパの良いパックです。夜のスキンケアに最適です。

参考になる／ある程度参考になる／あまり参考にならない／全く参考にならない

－ その他・意見感想

提案推薦システムは完成しているが、評価に際して比較可能性を担保するため、クエリは「ニキビに効く化粧水を教えてください」、「化粧のノリを良くするための商品はありますか?」、「夜に使うと効果的な保湿パックはありますか?」ユーザーの属性はシステムとのインタラクティブな対話により「21歳、敏感肌」と指定し、得られたアイテムを対象とする。セクション2からセクション4は、システムA (VR) とシステムB (VR+BGR) が提示した3つの推薦アイテムについて、提示アイテムの満足度、推薦理由の納得感、わかりやすさ、参考度の観点から質問を行った。Google フォームによるアンケートでは、「以下は実際に AI に商品を推薦してもらった結果の例です。二つのシステムを比較してください。また、ユーザーは 21 歳、敏感肌の方が質問した場合の結果になります。」という文言を各質問の冒頭に示した。3つの推薦例に使用した推薦理由を表2に示す。

6.2 推薦アイテムの満足度

表3に、提案手法による推薦アイテムの満足度に関するアンケート結果を示す。満足度に関するアンケート結果は、アイテム1～3のいずれも「満足」と回答した人の割合が一番高く、「やや不満」や、「非常に不満」と回答した人の割合は低いという結果が得られた。これより、提案手法によって得られた商品を推薦商品として決定する手法は有効であると考えられる。

6.3 推薦理由の比較

表4, 5, 6に、RAG (VR) を用いるシステムAと、RAG (VR+BGR) を用いる提案システムBによる推薦理由をわかりやすさ、納得感、参考度の観点で評価した結果を示す。わかりやすさについては、アイテム1～アイテム3において「システムB」を選択した回答者が過半数を占めた。一方で、「どちらもわかりにくい」と回答した人の割合は最も低かった。納得度については、アイテム1～アイテム3において「システムB」を選択した回答者が過半数を

占め、「どちらも納得できない」と回答した人の割合は最も低い結果となった。参考度については、アイテム1～アイテム3において「システムB」を選択した回答者が過半数を占め、「どちらも参考にならない」と回答した人の割合は最も低い結果となった。これらの結果から、アイテム1～アイテム3のすべてにおいて、システムBを選択した人が過半数を超え、システムAよりシステムBの方が高く評価されていることが確認された。特に、類似レビュアーのレビューを基に商品を推薦するアプローチは、ユーザーに対して肌質や年齢といった個別の特徴を考慮した推薦であると感じさせ、納得感を得やすくする要因であると考えられる。さらに、納得感の向上は、推薦理由の「参考度」や「わかりやすさ」にも好影響を与えている可能性がある。また、推薦理由が詳細に記述されていることに関するアンケート結果から、「簡潔な情報の方が良い」や「推薦理由は特に必要ない」という回答は少数にとどまっており、推薦理由は簡潔な情報だけでなく、具体的な説明を含む方がユーザーから高く評価される傾向にあることが分かる。このことから、詳細な説明を提供することで、ユーザーは自分に適した商品をより正確に判断でき、結果として満足度や信頼感が向上することが示唆される。

6.4 推薦理由に対する意見

表7と8に、推薦理由に関する総合的な意見を収集すべく行ったアンケート (セクション5) 結果を示す。表7より、推薦理由が詳細に記載されていることについては、「詳細な理由があると安心できる」と回答した人が55.5%であり、過半数を占める結果となった。また、「その他」の選択肢における自由記述では、「簡潔にまとめた文の後ろなどに詳細があるとわかりやすいと感じた」という意見も得られた。

表8より、推薦理由がレビューを基に生成されていることについては、「ある程度参考になる」と回答した人が70.3%、「非常に参考になる」と回答した人が18.9%であり、「あまり参考にならない」と回答した人は7.9%、「全く参考にならない」と回答した人は2.8%となった。これらの結果から、大多数の人々が推薦理由がレビューを基に生成されていることについて、参考になると考えていることが明らかになった。

表 3: 満足度

	非常に満足	満足	普通	やや不満	非常に不満	わからない
アイテム 1	14	121	101	14	2	65
	4.4%	38.2%	31.9%	4.4%	0.6%	20.5%
アイテム 2	17	162	74	9	2	53
	5.4%	51.1%	23.3%	2.8%	0.6%	16.7%
アイテム 3	34	155	73	2	2	51
	10.7%	48.9%	23.0%	0.6%	0.6%	16.1%

表 4: わかりやすさ

	システム A	システム B	どちらもわかりやすい	どちらもわかりにくい
アイテム 1	88	167	40	22
	27.8%	52.7%	12.6%	6.9%
アイテム 2	51	214	42	10
	16.1%	67.5%	13.2%	3.2%
アイテム 3	54	214	38	11
	17.0%	67.5%	12.0%	3.5%

表 5: 納得感

	システム A	システム B	どちらも同じくらい納得	どちらも納得できない
アイテム 1	72	162	56	27
	22.7%	51.1%	17.7%	8.5%
アイテム 2	51	193	56	17
	16.1%	60.9%	17.7%	5.4%
アイテム 3	52	211	40	14
	16.4%	66.6%	12.6%	4.4%

表 6: 参考度

	システム A	システム B	どちらも同じくらい参考になる	どちらも参考にならない
アイテム 1	69	166	57	25
	21.8%	52.4%	18.0%	7.9%
アイテム 2	40	199	64	14
	12.6%	62.8%	20.2%	4.4%
アイテム 3	44	204	56	13
	13.9%	64.4%	17.7%	4.1%

表 7: 推薦理由の必要性

詳細な理由があると安心できる	ある程度の理由があれば十分	簡潔な情報の方がいい	推薦理由は特に必要ない	その他
176	92	38	6	5
55.5%	29.0%	12.0%	1.9%	1.6%

表 8: 推薦理由の参考度（総合）

非常に参考になる	ある程度参考になる	あまり参考にならない	全く参考にならない
60	223	25	9
18.9%	70.3%	7.9%	2.8%

表 9: 参考度（普段のレビュー参考度別）


普段\今回	非常に参考になった	ある程度参考になった	あまり参考にならなかった	全く参考にならなかった
非常に参考にする	31 9.8%	61 19.2%	6 1.9%	2 0.6%
まあまあ参考にする	21 6.6%	105 33.1%	11 3.5%	2 0.6%
参考にしない	8 2.5%	57 18.0%	8 2.5%	5 1.6%

6.5 コスメに関する知識別による回答の差

評価アンケートの結果から、システム B が他のシステムと比較して比較的高い評価を得ていることが分かったが、システム B が特にどの層において有効であったのかを明らかにするため、コスメに関する知識の違いに着目して分析を行った。図 6 に、推薦理由の納得感と参考度に対する回答をコスメに対する知識別に集計した結果を示す。回答者の内訳は、「非常に詳しい」が 18 人、「基本的な知識はある」が 123 人、「ほとんど知らない」176 人であった。「非常に詳しい」と回答した人は全体、あるいは他の回答者群と比べて、「システム A」や「どちらも同じくらい」に回答が分散しており、システム B が比較的低く評価される傾向が見られる。非常に詳しい人の中で納得感と参考度についてシステム B の割合が低い理由として考えられるのは、詳しいからこそ期待値が高いことが理由として挙げられる。提案手法はレビューを基に推薦理由を提示しており、推薦文が一般ユーザー向けに近い文章であるため、科学的根拠のある成分説明や他商品との比較など専門性の部分で納得感と参考度を得られなかったと考えられる。

つづいて、普段コスメを購入する際に、レビュー

を参考にするか否かで集計を行った。表 9 は、普段のレビュー参考度ごとの「推薦理由が参考になったか」という問いに関する回答結果である。回答者の内訳は、普段レビューを「非常に参考にする」人が 100、「まあまあ参考にする」人が 139、「参考にしない」人が 78 であった。普段からレビューを参考にコスメを購入する層については、推薦理由がレビューを基に生成されている点に関して、「非常に参考になる」と回答した割合が高い。普段からレビューを参考にコスメを購入している人にとって提案手法は推薦システムとして有効である可能性が考えられる。一方で、コスメを買う際にレビューをある程度参考にする層や、参考にしない層については、推薦理由がレビューが基になっている点について、「ある程度参考にする」の割合は 7 割近くあるが、「非常に参考にする」と回答した人は 10 % にとどまっていることから、レビューを基に推薦理由を生成することは、この層には限定的である。この層はレビューを完全に否定しているわけではないが、サクラかどうかや、商品情報、ブランドイメージ、成分など他の情報も重要視している可能性がある。



7 おわりに

本研究では、LLM を用いたコスメアイテム推薦において、説得力のある推薦理由を添えることを目的とし、LLM のハルシネーション軽減のために一般的に用いられるベクトル検索による RAG に加えて、二部グラフ検索を組み合わせた推薦するシステムを構築した。具体的には、ユーザーからの問い合わせを受けて関連するレビュー文をベクトル検索により取得し、その情報を基に二部グラフ検索によりアイテムやレビュアーのレビュー情報を補完することで、LLM は個別のニーズに基づいて最適なアイテムを推薦し、その理由を明示することができた。

結果として、RAG (VR) は簡易的ではあるが信頼性に限界があり、納得感のある推薦理由の提示がユーザー満足度を向上させることが示唆された。提案システム RAG (VR+BGR) は、ユーザーの特徴を考慮した推薦において有効であることが確認できた。推薦理由の詳細さがユーザー満足度に与える影響を考慮すると、単に関連性の高いレビューを用いるだけでなく、ユーザー個別の特徴を反映した説明を加えることがシステム評価を向上させる重要なポイントであることが示唆される。提案手法は、レビューを重視する層や初心者層には効果的だが、レビューを重要視しない層や専門的な情報を求める層には課題が残ることが分かった。

今後の課題として、専門的な知識を求める層への対応策が挙げられる。具体的には、知識グラフ検索 (Knowledge-Graph Retrieval ; KGR) を活用して、製品情報や科学的根拠に基づく成分の効能などをグラフデータベースとして構築し、それをクエリ応答の基盤として活用することで、システム要件の網羅性を満たす仕組みを構築する必要がある。このアプローチにより、レビュー情報だけでなく、科学的な裏付けや専門知識に基づいた回答を提供できる。たとえば、クエリに含まれていない関連成分や効能に関する知識を動的に取得し、それを説明可能な形で提示することで、専門的な知識を求める層のニーズに応えることができる。さらに、BGR にレビュー文の推奨度・非推奨度を導入することで、さらなるユーザー満足度向上につなげていきたい。

データセットの利用可能性宣言

本研究中に作成された、分析に用いたデータセットは、妥当な理由があれば責任著者から入手可能である。

参考文献

- [1] Gao, Yunfan; Xiong, Yun; Gao, Xinyu; Jia, Kangxiang; Pan, Jinliu; Bi, Yuxi; Dai, Yi; Sun, Jiawei; Wang, Meng; Wang, Haofen: “Retrieval-Augmented Generation for Large Language Models: A Survey”, *arXiv preprint arXiv:2312.10997*, 2024.
- [2] Xu, Jian; Luo, Sichun; Chen, Xiangyu; Huang, Haoming; Hou, Hanxu; Song, Linqi: “RALLRec: Improving Retrieval Augmented Large Language Model Recommendation with Representation Learning”, *Companion Proceedings of the ACM Web Conference 2025 (WWW Companion '25)*, pp. 1–5, Sydney, NSW, Australia, 2025. ACM.
- [3] Luo, Sichun; Xu, Jian; Zhang, Xiaojie; Wang, Linrong; Liu, Sicong; Hou, Hanxu; Song, Linqi: “RALLREC+: Retrieval Augmented Large Language Model Recommendation with Reasoning”, *arXiv preprint arXiv:2503.20430*, 2025. Extended version, includes retrieval and reasoning enhancements for LLM-based recommender systems.
- [4] Alamri, Faten S.; Rehman, Amjad; Alghofaily, Bayan; Ahmed, Adeel; Saleem, Khalid: “Leveraging RAG With Transformer for Context-Based Personalized Recommendations”, *IEEE Access*, Vol. 13, pp. 97472–97486, 2025.
- [5] Dong, Guanting; Zhu, Yutao; Zhang, Chenghao; Wang, Zechen; Wen, Ji-Rong; Dou, Zhicheng: “Understand What LLM Needs: Dual Preference Alignment for Retrieval-Augmented Generation”, *Proceedings of the ACM Web Conference 2025*

- (WWW '25), pp. 1–20, Sydney, NSW, Australia, 2025. ACM.
- [6] Wang, Shijie; Fan, Wenqi; Feng, Yue; Lin, Shanru; Ma, Xinyu; Wang, Shuaiqiang; Yin, Dawei: “Knowledge Graph Retrieval-Augmented Generation for LLM-based Recommendation”, *arXiv preprint arXiv:2501.02226*, 2025.
- [7] Meng, Zeyuan; Yi, Zixuan; Ounis, Iadh: “KERAG_R: Knowledge-Enhanced Retrieval-Augmented Generation for Recommendation”, *arXiv preprint arXiv:2507.05863*, 2025.
- [8] Azizi, Vahid; Koochaki, Fatemeh: “LLAMAREC-LKG-RAG: A SINGLE-PASS, LEARNABLE KNOWLEDGE GRAPH-RAG FRAMEWORK FOR LLM-BASED RANKING”, *arXiv preprint arXiv:2506.07449*, 2025.
- [9] Qiu, Zhangchi; Luo, Linhao; Zhao, Zicheng; Pan, Shirui; Liew, Alan Wee-Chung: “Graph Retrieval-Augmented LLM for Conversational Recommendation Systems”, *arXiv preprint arXiv:2503.06430*, 2025.
- [10] Tourani, Ali; Nazary, Fatemeh; Deldjoo, Yashar: “RAG-VISUALREC: An Open Resource for Vision- and Text-Enhanced Retrieval-Augmented Generation in Recommendation”, 2025.

(2025年 2月10日 受付)

(2025年10月10日 採択)

(2025年11月14日 J-STAGE早期公開)