

文書のチャンクに基づく GraphRAG と コミュニティ分類に基づく GraphRAG の比較分析

Comparative Analysis of GraphRAG Based on Document Chunks and GraphRAG Based on Community Selection of Knowledge Graph

穴口史将 *1*2
Fumikatsu Anaguchi

チャクラボルティ シュデシナ *1
Sudesna Chakraborty

森田武史 *1*2
Takeshi Morita

江上周作 *2
Shusaku Egami

鵜飼孝典 *2*3
Takanori Ugai

福田賢一郎 *2
Kenichiro Fukuda

*1 青山学院大学
Aoyama Gakuin University

*2 産業技術総合研究所
National Institute of Advanced Industrial Science and Technology

*3 富士通株式会社
Fujitsu Limited

Retrieval-Augmented Generation (RAG) has gained attention as an approach for Large Language Models (LLMs) to utilize external knowledge. In RAG, various extension methods have been explored for each module. In particular, retrieval modules have been extensively studied, with a primary focus on similarity retrieval methods using embedding vectors. Additionally, GraphRAG, which leverages knowledge graphs, is expected to structure information and identify relationships between entities. However, the structural differences and construction methodologies of knowledge graphs in GraphRAG remain unclear. In this study, we compare two GraphRAG approaches: one based on semantic chunking and the other based on community-based knowledge graph classification. Using an information-seeking QA dataset derived from academic publications, we analyze the differences in the knowledge graphs generated by these methods from the perspectives of domain knowledge representation and contextual understanding. Additionally, through a comparative evaluation of QA task performance, we discuss the existing challenges and potential improvements in GraphRAG methodologies.

1. はじめに

大規模言語モデル (Large Language Model, LLM) を活用したシステムは質問応答をはじめ、様々なタスクで最先端な性能を凌駕している。しかしながら、LLM の学習データに存在しない知識に関する質問応答ではハルシネーションの課題があり、その解決策として外部知識の活用の研究が進んでいる。中でも、Retrieval-Augmented Generation (RAG) は導入コスト、知識の更新、情報源の提示などにおいて優れており、注目を浴びている。しかし、データベース内の異なるエンティティ間の複雑な関係構造を適切に考慮することが、RAG における情報検索の課題となる。これに対し、GraphRAG [Peng 24] はエンティティ間の構造情報を活用することで、より正確な検索と文脈を考慮した回答が期待される。しかし、GraphRAG における知識グラフの構造や構築方法は異なっており、それらの類似点や相違点は明らかではない。

本研究では、学術論文を対象とした情報探索 QA データセットを用いて、文書のチャンクに基づく GraphRAG 手法と知識グラフのコミュニティ分類を活用した GraphRAG 手法を比較する。また、これらの手法で構築される知識グラフの差異を分析するとともに、QA タスクの比較評価を通じて、現状の課題と手法改善について議論する。

2. 関連研究

2.1 文書のチャンクに基づく GraphRAG

RAG において、LLM に最終的に入力されるプロンプトには、質問に類似した文脈情報が追加される。しかし、質問に回答する上で必要な知識は、必ずしも質問に類似するチャンクに

含まれるとは限らない。ユーザの要求の種類は単に主語や目的語を問う質問だけでなく、原因や結果を問う質問も想定され、これらの質問に回答する上で必要なチャンクは、質問の類似性の高いチャンクは分割されている可能性がある。

以上の背景を踏まえ、文書のチャンクに基づく GraphRAG [江上 24] では、外部文書のチャンクのメタデータやチャンク間の意味的关系を抽出することで知識グラフを構築し、ベクトル類似度と組み合わせたハイブリッドな RAG 手法を提案した。[江上 24] の概要図を図 1 に示す。知識グラフ (KG) は各チャンクの 5W1H 情報とチャンク間の談話関係を含む。質問文の埋め込みベクトルを用いた類似度検索により取得したチャンクから、知識グラフを検索し、談話関係を辿ることで関連するチャンクを取得する。また、質問文から抽出した 5W1H 情報をもとにグラフ検索を行い、関連するチャンクを取得する。取得したすべてのチャンクをリランクしてプロンプトを作成し、LLM へ入力することで文脈の沿った回答を得る。実験の結果、ベースラインと比較して回答の忠実性とコンテキストの向上が確認された。

2.2 コミュニティ分類に基づく GraphRAG

RAG によって、LLM は外部知識を活用した生成が可能となり、ドメイン固有の知識を参照することができる。しかし、文書全体を対象とする質問に対しては、検索と保持に課題がある。このような大量のテキストは、LLM のコンテキストウィンドウの制限を超える可能性があり、長いコンテキストの中で情報が失われる可能性がある。

以上の背景を踏まえ、コミュニティ分類に基づく GraphRAG [Edge 24] では、LLM を用いて文書から知識グラフを構築し、インデックスされたテキストを検索する RAG 手法を提案した。[Edge 24] の概要図を図 2 に示す。文書を分割し、ノードとエッジのインスタンスを特定し、ノードとエッジに対して、その説明となるノード要約を付与する。これらインデックスは、エンティティノードが関係エッジで

連絡先: 森田武史, 青山学院大学理工学部, 〒 252-5258
神奈川県相模原市中央区淵野辺 5-10-1, E-mail:
morita@it.aoyama.ac.jp




図 1: 文書のチャンクに基づく GraphRAG の概要




図 2: コミュニティ分類に基づく GraphRAG の概要

接続され、無向グラフとしてモデル化される。この知識グラフをコミュニティに基づいて分類し、コミュニティに対して要約情報を付与する。これらのデータを用いて、複数段階のプロセスで最終的な回答を生成する。実験の結果、ベースラインと比較して回答の包括性と多様性の向上が確認された。

3. 実験

3.1 実験概要

本実験では、文書のチャンクに基づく GraphRAG とコミュニティ分類に基づく GraphRAG を対象として、学術論文情報探索 QA データセットを用いた実験による精度比較と、これらの手法で構築される知識グラフを比較する。RAG の実装には、OpenAI 社の埋め込みモデル「text-embedding-3-small」および LLM「gpt-4o-mini-2024-07-18」を用いる。また、専門知識と文脈理解の観点で分析し、現状の課題と手法改善について議論する。

3.2 データセット

本実験では、自然言語処理分野の学術論文を対象とした情報探索型の QA データセット QASPER [Dasigi 21] を用いる。本データセットにおける学術論文は arXiv に投稿されたものであり、各データはテキストデータとして保存されている。各質問は、対象の論文のタイトルとアブストラクトのみを読んだ自然言語処理の専門家によって作成される。質問は論文全体に含まれる情報を求めるものであり、タイトルとアブストラクトからでは回答できないが、本文のどこかで回答が期待されるものである。各回答は別の自然言語処理の専門家によって、論文の本文をもとに作成される。

各質問は、回答が本文から抽出されるもの（抽出型）、本文全体の要約が必要なもの（要約型）、Yes か No で回答できるもの

表 1: QASPER における各質問型の事例数の割合と質問・回答例

質問型	割合	質問例	回答例
抽出	51.8%	What five dialogue attributes were analyzed?	Confidence; Continuity; Queryrelatedness; Repetitiveness; Specificity
要約	24.2%	Which neural architecture do they use as a base for their attention conflict mechanisms?	GRU-based encoder, interaction block, and classifier consisting of stacked fullyconnected layers.
Yes/No	13.9%	Do they use off-the-shelf NLP systems to build their assitant?	No
回答不能	10.2%	What language are the caption-sin?	N/A

(Yes/No 型)、回答が不可能なものに分類される。QASPER は、1,585 本の論文に対して 5,049 件の質問と回答の組（事例）を保持している。各論文には平均で 3.2 件の事例があり、一つの論文につき最大で 12 件の事例が含まれている。

表 1 に QASPER における各質問型の事例数の割合と質問・回答例を示す。本実験では、本データセットの回答不能を除く各質問型からランダムに抽出された 100 事例に対して、自動評価尺度を用いて評価する。

表 2: 抽出型 QA タスクの実験結果

手法名	完全一致率	適合率	再現率	F 値
RAG	0.01	0.53	0.14	0.20
文書のチャンクに基づく GraphRAG	0.01	0.62	0.18	0.25
コミュニティ分類に基づく GraphRAG	0.03	0.64	0.25	0.31

表 3: 要約型 QA タスクの実験結果

手法名	BLEU	適合率	再現率	F 値
RAG	0.15	0.52	0.50	0.51
文書のチャンクに基づく GraphRAG	0.15	0.51	0.49	0.49
コミュニティ分類に基づく GraphRAG	0.17	0.54	0.52	0.52

3.3 評価指標

抽出型の QA タスクでは、完全一致率、適合率、再現率、F 値を用いて評価を行い、文単位およびトークン単位での一致率を測る。要約型の QA タスクでは、BLEU と BERTScore を用いて評価を行い、トークン単位での意味的な類似性を考慮した一致率を測る。また、Yes/No 型の QA タスクでは、完全一致率のみを評価指標として用いる。

3.4 実験結果

3.4.1 QA タスクを用いた実験結果

表 2 に抽出型 QA タスクの実験結果を示す。抽出型 QA タスクでは、すべての評価尺度においてコミュニティ分類に基づく GraphRAG が最も高い性能を示した。また、適合率、再現率、F 値においては、文書のチャンクに基づく GraphRAG が RAG よりも高い性能を示した。

表 3 に要約型 QA タスクの実験結果を示す。要約型 QA タスクでも、すべての評価尺度においてコミュニティ分類に基づく GraphRAG が最も高い性能を示した。一方、RAG は文書のチャンクに基づく GraphRAG より高い性能を示した。

表 4 に Yes/No 型 QA タスクの実験結果を示す。Yes/No 型 QA タスクでは、文書のチャンクに基づく GraphRAG が他の手法より高い性能を示した。

表 5 と表 6 に抽出型 QA タスクの成功例と失敗例を示す。また、文書のチャンクに基づく GraphRAG では、正解となる記述が文書中に存在するにも関わらず、「文書に明記されていない」と出力されるケースが多く見られた。

3.4.2 知識グラフ検索の比較の結果

本項では、“Which tasks are explored in this paper?” を質問として、“generative model evaluation and document classification” を正解とする抽出型 QA タスクを対象として、各 GraphRAG が構築した知識グラフの検索例を示す。

文書のチャンクに基づく GraphRAG における知識グラフの検索例を図 3 に示す。検索プロセスは実線で表記し、知識グラ

表 4: Yes/No 型 QA タスクの実験結果

手法名	完全一致率
RAG	0.51
文書のチャンクに基づく GraphRAG	0.54
コミュニティ分類に基づく GraphRAG	0.49

表 5: 抽出型 QA タスクの成功例

手法	質問	生成結果
RAG	What domain of text are they working with?	news articles
文書のチャンクに基づく GraphRAG	How many different strategies were evaluated?	14
コミュニティ分類に基づく GraphRAG	What pretrained language model is used?	BERT

表 6: 抽出型 QA タスクの失敗例

手法	質問	生成結果	正解
RAG	What language are the captions in?	Italian	English
文書のチャンクに基づく GraphRAG	what dataset was used?	USC-TIMIT database	simultaneous speech EEG recording databases
コミュニティ分類に基づく GraphRAG	What language are the captions in?	The captions are in English	English

フのエッジは点線で表記する。この手法では、ベクトル検索を用いて、質問に類似する“quantitative experiments”が検索される。次に、“quantitative experiments”から、グラフ検索を用いて 5W1H を部分的に持つチャンクを検索する。ここでは、“quantitative experiments”を“what”として保持するチャンクが検索される。コミュニティ分類に基づく GraphRAG における知識グラフの検索例を図 4 に示す。この手法では、質問と最も類似するコミュニティやノードが選択される。

3.5 考察

3.5.1 QA タスクを用いた実験の考察

本実験の結果から、抽出型および要約型 QA タスクにおいて、コミュニティ分類に基づく GraphRAG が最も高い性能を示した。この結果は、学術論文のような専門的な文書において、情報を圧縮・要約し、関連する文脈を提供することが、より適切な回答生成につながることを示唆する。

抽出型 QA タスクにおける適合率の結果から、文書のチャンクに基づく GraphRAG とコミュニティ分類に基づく GraphRAG では、文単位での正確な抽出は困難である一方、トークン単位では、ある程度正確な抽出が可能であることが示された。また、文書のチャンクに基づく GraphRAG は、具体的な人物名や手法名の取得を通じて性能の向上が見られた。例えば、「定量評価」などの概念をベクトル検索し、手法名や著者、効果といった情報をグラフ検索によって補完することで、より詳細な情報を取得できることが確認された。一方、コミュニティ分類に基づく GraphRAG は、RAG に比べて更なる性能向上を示し、特に、国名を含む回答の抽出において性能の向上が確認された。また、RAG と比較すると、他の二手法では「」を「and」に書き換える傾向と質問において省略された主語を補完する傾向が観察された。これは、より文脈を考慮した回答生成を試みた結果であると考えられる。

要約型 QA タスクの評価では、文書のチャンクに基づく




図 3: 文書のチャンクに基づく GraphRAG における知識グラフの検索例




図 4: コミュニティ分類に基づく GraphRAG における知識グラフの検索例

GraphRAG は、RAG に比べて全体的に性能が低下したものの、RAG では回答が困難であった問題に対して適切な回答を生成することが確認された。特に、手法を問う質問に対しては、手法の目標や具体的な内容を含めた、より適切な回答を生成できた。

Yes/No 型 QA タスクの評価では、グラフ検索の結果が有効に機能していることが確認された。これは、グラフ検索によって正確に回答根拠となる記述が抽出され、それが回答生成の性能向上に寄与したためであると考えられる。

本実験の結果から、「データセットの規模感はどうのくらいですか？」や「実験結果はどうですか？」といった曖昧な質問に対する回答において、意図がずれるケースが確認された。これらの質問に対して適切な回答を得るためには、データの詳細を補完するための追加処理が必要であると考えられる。

3.5.2 知識グラフ検索の比較の考察

本実験では、それぞれの GraphRAG が構築した知識グラフを比較し、それぞれの特性を分析した。文書のチャンクに基づく GraphRAG が構築した知識グラフは、5W1H と談話関

係を用いて、質問に関する具体的で詳細な情報を取得することに優れている。ベクトル検索により取得したキーワードをもとに逐次的な検索を行い、そのノードに関連する情報を抽出することが可能であった。一方、コミュニティ分類に基づく GraphRAG は、文書全体のトピックを考慮し、関連する概念の集合として情報を整理するため、広範な知識を踏まえた回答生成が可能であった。

3.6 現状の GraphRAG 手法の課題と手法改善の考察

文書のチャンクに基づく GraphRAG は、文脈を広く捉える必要がある質問に対して不完全な回答が生成される傾向があり、コミュニティ分類に基づく GraphRAG は、具体的な手法名や定量的な結果の正確な取得が難しい場合があった。また、両手法ともにノードの抽出や知識グラフの構築に LLM を用いるため、情報が欠損した不完全な知識グラフが構築される可能性がある。文書のチャンクに基づく GraphRAG では、談話関係の抽出が不十分な場合があり、コミュニティ分類に基づく GraphRAG では、一部の情報が省略されるケースが確認された。これらの結果から、文章全体の概念や事物の関連を、より正確に表現できる知識グラフの構築が必要だと考えられる。また、質問の意図や性質に応じて、ベクトル検索とグラフ検索を組み合わせた検索アルゴリズムの設計が必要だと考えられる。

4. おわりに

本研究では、学术论文を対象とした情報探索 QA データセットを用いて、文書のチャンクに基づく GraphRAG 手法と知識グラフのコミュニティ分類を活用した GraphRAG 手法を比較した。本実験では、抽出型および要約型 QA タスクにおいて、コミュニティ分類に基づく GraphRAG が最も高い性能を示した。この結果は、学术论文のような専門的な文書において、情報を圧縮・要約し、関連する文脈を提供することが、より適切な回答生成につながることを示唆する。また、文書のチャンクに基づく GraphRAG では、質問に関する具体的で詳細な情報を取得することで、RAG より高い性能を示した。

謝辞

本研究成果の一部は、国立研究開発法人新エネルギー・産業技術総合開発機構 (NEDO) の委託業務 (JPNP20006) の結果得られたものです。本研究は JSPS 科研費 23K11221 の助成を受けたものです。

参考文献

- [Dasigi 21] Dasigi, P., et al.: A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers, in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 4599–4610 (2021)
- [Edge 24] Edge, D., et al.: From Local to Global: A Graph RAG Approach to Query-Focused Summarization (2024)
- [Peng 24] Peng, B., et al.: Graph Retrieval-Augmented Generation: A Survey (2024)
- [江上 24] 江上周作, 福田賢一郎: 文書のチャンクに基づく知識グラフを活用した RAG, 言語処理学会第 30 回年次大会, Vol. C9-2, pp. 1–4 (2024)